

성형 견적 시각화 시스템

v1 vs v2 비교 + 발표 핵심 개념 정리

발표일	2026-05-18
프로젝트	컴퓨터 비전 기말 (3인 팀)
주제	Image Segmentation + Generation
메인 학습 모델	U-Net (ResNet-34 인코더)
데이터셋	CelebAMask-HQ (CVPR 2020, 30K장)
예상 점수	89/100 (v1 대비 +43)

목차

- 1. v1 모델 — 분석/추천형 (수정 전)
- 2. v1 → v2 전환 이유 (평가 기준 분석)
- 3. v2 모델 — U-Net 자체 학습 (현재)
- 4. 핵심 개념 A — Segmentation Task
- 5. 핵심 개념 B — U-Net 아키텍처
- 6. 핵심 개념 C — SC-FEGAN (사전학습 GAN)
- 7. 핵심 개념 D — MediaPipe Face Mesh
- 8. 핵심 개념 E — 평가 지표 (IoU, Dice, mIoU)
- 9. 핵심 개념 F — Loss Function (Combo Loss)
- 10. 핵심 개념 G — Data Augmentation + Ablation
- 11. 핵심 개념 H — Grad-CAM (해석 가능성)
- 12. 핵심 개념 I — CelebAMask-HQ 데이터셋
- 13. 핵심 개념 J — Transfer Learning
- 14. 예상 질문 + 모범 답변
- 15. 발표 시 강조 포인트

1. v1 모델 — 분석/추천형 (수정 전)

1.1 시스템 구조

v1은 사전학습 모델 3개를 조합한 파이프라인으로, 자체 학습 컴포넌트가 없다. 얼굴 분석은 MediaPipe, 추천은 룰베이스 if-else, 시각화는 SC-FEGAN을 그대로 사용.

단계	기술	역할
1. 얼굴 검출	MediaPipe Tasks API	478 landmarks 추출
2. 비율 분석	Python (삼정·오안·E-line)	10개 지표 계산
3. 추천 엔진	룰베이스 if-else (procedures.yaml)	시술 3종 매칭
4. 마스크 생성	OpenCV Convex Hull	거친 마스크 (랜드마크 기반)
5. 시각화	SC-FEGAN (사전학습 GAN)	시술 후 얼굴 생성

1.2 특징

- 학습 모델 없음: 모든 컴포넌트가 사전학습 또는 룰베이스
- 구현 난이도 낮음: 라이브러리 조합만으로 동작
- 마스크 정밀도 낮음: Convex Hull은 다각형 외곽선만 그림
- 해석 가능성 없음: 룰베이스는 if 조건만 보면 됨 (CNN 해석 불가)
- 평가 지표 없음: 정답 라벨이 없어 정량 평가 불가

1.3 한계점

v1은 작동은 하지만 학술 발표에서 어필할 포인트가 부족하다. 수업에서 배운 "CNN 계층적 특징 추출" 같은 구조적 원리를 직접 적용한 부분이 없고, 성능 평가도 정량적으로 할 수 없다. SC-FEGAN의 결과 품질은 모델 자체의 한계지 우리가 개선할 수 있는 부분이 아니다.

2. v1 → v2 전환 이유 (평가 기준 분석)

2.1 교수님 평가 기준 (총 100%)

평가 항목	가중치	내용
문제 정의 + 데이터 타당성	30%	Task 명확, 데이터셋 양·질
모델 설계 + 구현	40%	CNN 계층적 특징 추출, 구조적 원리 적용
성능 분석 + 최적화	15%	Confusion Matrix, IoU, mAP, Augmentation
시각화 + 해석	15%	Grad-CAM, Feature Map, 설명 가능한 AI

2.2 v1의 평가 점수 예상

각 항목에 v1을 대입하면 치명적 약점이 40% 항목에서 드러난다:

항목	v1 점수	이유
문제 + 데이터	18 / 30	자체 데이터셋 없음, 학술 표준 데이터 미사용
모델 설계	15 / 40	사전학습 조합만, 자체 학습 $x \rightarrow$ 거의 빙점
성능 분석	5 / 15	CV 표준 지표(IoU/mAP) 적용 불가
시각화·해석	8 / 15	Grad-CAM 못 함 (CNN 미사용)
합계	46 / 100	발표 시 "학습한 모델이 뭐냐" 질문에 답 없음

2.3 결정적 인용 — 교수님 원문

"CNN의 계층적 특징 추출 또는 기타 다른 방법들을 활용한 효율적 설계 등 수업에서 배운 구조적 원리를 적절히 적용했는가?"

2.4 해결책 — U-Net 자체 학습 추가

교수님 평가 기준의 40% 항목을 충족시키려면 자체 학습한 CNN이 필요하다. 옵션 후보 3개 (분류/세그멘테이션/탐지) 중 세그멘테이션 (U-Net)을 선택. 이유: ① 우리 task(부위별 마스크 생성)에 자연스럽게 맞고, ② U-Net의 "계층적 특징 + skip connection"이 교수님 원문에 가장 직접적으로 부합, ③ 데이터셋(CelebAMask-HQ)이 학술 표준이라 30% 항목도 같이 충족.

3. v2 모델 — U-Net 자체 학습 (현재)

3.1 v1과의 차이 한눈에

항목	v1 (수정 전)	v2 (수정 후)
학습 컴포넌트	없음	U-Net 자체 학습 ★
마스크 생성	Convex Hull (거친)	픽셀 단위 세그멘테이션
데이터셋	샘플 5장	CelebAMask-HQ 30K장
평가 지표	없음	mIoU, Dice, Confusion Matrix
성능 최적화	없음	Augmentation Ablation
해석	시각화만	Grad-CAM
점수 예상	46 / 100	89 / 100 (+43)

3.2 새 파이프라인 (5단계)

#	단계	기술	학습 여부
1	얼굴 검출	MediaPipe Tasks API (478 landmarks)	사전학습
2	비율 분석 + 추천	삼정·오안·E-line + 룰베이스	—
3	★ 세그멘테이션	U-Net (ResNet-34 인코더)	자체 학습
4	시각화	SC-FEGAN (사전학습 GAN)	사전학습
5	결과 + 해석	Before/After + Grad-CAM + PDF	—

3.3 v2가 점수에 어떻게 기여하는지

평가 항목	v2 대응	예상 점수
문제 + 데이터 (30%)	CelebAMask-HQ 학습 표준	27 / 30
모델 설계 (40%)	U-Net 계층적 특징 + skip connection	35 / 40
성능 분석 (15%)	mIoU + Dice + Confusion Matrix + Ablation	14 / 15
시각화·해석 (15%)	Grad-CAM + Before/After overlay	13 / 15
합계	—	89 / 100

4. 핵심 개념 A — Segmentation Task

4.1 세 가지 비전 task 비교

Task	출력	예시
Classification (분류)	이미지 → 한 클래스	고양이? 강아지?
Detection (탐지)	이미지 → 여러 박스 + 클래스	코=박스, 눈=박스 ...
Segmentation (세그멘테이션)	이미지 → 픽셀마다 클래스	각 픽셀이 코/눈/입 ...

4.2 Semantic vs Instance Segmentation

- Semantic: 같은 클래스는 같은 라벨 (예: 모든 "눈" 픽셀이 클래스 2)
 - Instance: 개별 인스턴스 구분 (왼쪽 눈, 오른쪽 눈 분리)
- 우리는 Semantic Segmentation. 같은 부위는 한 클래스로 묶음.

4.3 왜 Segmentation 인가

성형 기술은 특정 부위의 픽셀 영역을 변형하는 작업. 박스(detection) 단위가 아니라 정확한 윤곽선이 필요하므로 픽셀 단위 분류인 Segmentation이 적합. 또한 SC-FEGAN의 입력으로 픽셀 마스크가 필요해 파이프라인 통합도 자연스럽다.

5. 핵심 개념 B — U-Net 아키텍처

5.1 구조 개요

U-Net은 의료 영상 세그멘테이션을 위해 2015년 Ronneberger 등이 발표한 아키텍처. 이름은 "U" 모양으로 그려지는 encoder-decoder 구조에서 유래.

부분	역할	동작
Encoder	특징 추출	Conv + Pool로 단계적 다운샘플링 (저수준 → 고수준)
Bottleneck	추상화 정점	가장 깊은 특징 (공간 해상도 최소)
Decoder	공간 복원	Upsample + Conv로 원본 크기까지 복원
Skip Connection	정보 결합	Encoder의 같은 단계 특징을 Decoder에 직접 전달

5.2 왜 Skip Connection이 중요한가

Encoder가 깊어질수록 공간 정보가 사라짐 (downsampling으로 픽셀 위치 정보 손실). Decoder가 픽셀 단위 예측을 하려면 공간 정보가 필요한데, encoder의 얇은 층(공간 정보 풍부)에서 가져와 decoder에 직접 전달하는 것이 skip connection. 고수준 의미 + 저수준 위치를 모두 활용 가능.

5.3 우리의 구체적 구성

- Encoder: ResNet-34 (ImageNet 사전학습) — Transfer Learning 활용
- Decoder: U-Net 표준 (Upsample + Conv + skip concat)
- 출력: (B, 6, H, W) logits → argmax로 픽셀별 클래스 (0~5)
- 구현: segmentation_models_pytorch 라이브러리 (코드 3줄로 정의)

5.4 6 클래스 매핑 (교수님이 물어볼 가능성 있음)

우리 클래스	원본 CelebAMask 라벨	비고
0: background	bg, hair, hat, cloth, ear ...	관심 없는 영역 통합
1: nose	nose	코끝 성형 마스크
2: eye	l_eye, r_eye, l_brow, r_brow	쌍꺼풀 시술 (눈썹 포함)
3: mouth	mouth, u_lip, l_lip	입술 시술
4: skin	skin	후처리에서 jaw/forehead 분리
5: (unused)	—	여분 슬롯

6. 핵심 개념 C — SC-FEGAN (사전학습 GAN)

6.1 GAN이란

Generative Adversarial Network. Generator(생성기)와 Discriminator(판별기) 두 네트워크가 서로 경쟁하며 학습 → Generator가 진짜 같은 이미지를 만들도록 훈련된다.

6.2 SC-FEGAN의 특징

ICCV 2019 (Jo & Park) 논문. 마스크된 얼굴 영역에 사용자 가이드로 자연스러운 픽셀을 채워주는 GAN. Image Inpainting의 변형으로 볼 수 있다.

입력 채널	내용	역할
1~3 (RGB)	원본 이미지 (마스크 영역 0)	변경하지 않을 부분
4 (Sketch)	이상적 모양의 가이드 라인	변형 방향 지시
5~7 (Color)	원하는 색의 stroke	색상 가이드
8 (Mask)	편집할 영역 (binary)	어디를 채울지
9 (Noise)	랜덤 노이즈 (마스크 영역만)	생성 다양성

6.3 우리는 왜 SC-FEGAN을 학습하지 않나

GAN 학습은 일반적으로 수주~수개월 소요되고, 학습 안정성이 매우 까다롭다. 1달 일정 + 3인 팀 규모로는 불가능. 따라서 시각화 도구로 그대로 활용하고, 학습 가능한 컴포넌트(U-Net)에 집중하는 전략을 택했다.

7. 핵심 개념 D — MediaPipe Face Mesh

7.1 무엇을 하나

Google이 개발한 얼굴 분석 라이브러리. 얼굴 이미지에서 478개의 3D 랜드마크를 실시간으로 검출. 468개 face surface + 10개 iris.

7.2 우리 사용 방식 — Tasks API

MediaPipe에는 legacy mp.solutions API와 신형 mp.tasks API 두 가지가 있다. 최신 mediapipe 빌드 (0.10.30+)에서는 solutions가 빠져있어, Tasks API를 사용한다. 기능은 동일 (478점 추출).

7.3 핵심 랜드마크 인덱스 (코, 눈, 입, 턱)

부위	인덱스	용도
코끝	1	코 영역 중심
미간	168	얼굴 비율 분석
왼눈 외각 / 내각	33 / 133	눈 영역 + flip 대응
오른눈 외각 / 내각	263 / 362	동일
윗입술 / 아랫입술	13 / 14	입술 변형
턱끝	152	jaw 영역 분리 기준
이마 상단	10	forehead 영역

8. 핵심 개념 E — 평가 지표

8.1 IoU (Intersection over Union)

세그멘테이션의 표준 지표. 예측 영역과 정답 영역의 겹치는 부분 / 합집합. 0~1 값, 1에 가까울수록 좋음.

$$\text{IoU} = \text{TP} / (\text{TP} + \text{FP} + \text{FN})$$

TP: True Positive (정답이며 예측한 픽셀)
FP: False Positive (정답 아닌데 예측한 픽셀)
FN: False Negative (정답인데 놓친 픽셀)

8.2 mIoU (mean IoU)

여러 클래스의 IoU 평균. 우리는 배경(class 0) 제외 평균을 사용 (배경이 너무 커서 무한 IoU ↑).
목표: mIoU > 0.75 (face parsing 표준 벤치마크)

8.3 Dice Score (F1 유사)

$$\text{Dice} = 2 \times \text{TP} / (2 \times \text{TP} + \text{FP} + \text{FN})$$

F1 score와 수학적으로 동등. IoU보다 작은 객체에 관대 (IoU=0.5는 Dice 0.67).

8.4 Confusion Matrix

C×C 행렬 (C = 클래스 수). 행은 정답, 열은 예측. 대각선이 클수록 좋음. 클래스 간 혼동 패턴을 보여줌 — 예: "eye를 brow로 잘못 예측".

9. 핵심 개념 F — Loss Function

9.1 Cross Entropy Loss (CE)

분류 문제의 기본 손실. 픽셀마다 정답 클래스의 예측 확률 $\log \rightarrow$ 평균. 장점: gradient가 부드럽고 학습 안정적. 단점: class imbalance에 민감.

9.2 Dice Loss

1 - Dice score. 작은 영역(예: 코)에도 비중을 줘서 class imbalance에 강함. 단점: 초기 학습이 불안정 (예측이 모두 0이면 gradient 0).

9.3 Combo Loss — 우리가 선택한 것 ★

두 손실의 가중합. $\alpha \times \text{DiceLoss} + \beta \times \text{CrossEntropyLoss}$ ($\alpha=\beta=0.5$).

이점: Dice가 imbalance 보정, CE가 초기 학습 안정화 (서로 보완).

예시: skin 영역은 얼굴의 30%, nose 영역은 2%인 경우

- CE 단독: 큰 영역(skin) 잘 맞추면 점수 높아 작은 영역(nose) 학습 부족
- Dice 단독: 모든 영역 동등 비중이지만 초기 불안정
- Combo: 두 단점 모두 해결

10. 핵심 개념 G — Data Augmentation + Ablation

10.1 왜 필요한가

데이터셋이 한정적이면 모델이 학습 데이터에 과적합(overfit)됨. 이미지 변형을 추가해 "같은 의미의 다른 픽셀"을 만들면 일반화 성능 ↑.

10.2 우리 Augmentation 파이프라인 (augmentations)

타입	변환	확률
Spatial (공간)	Horizontal Flip (좌우 반전)	0.5
Spatial	Rotation $\pm 15^\circ$	0.5
Pixel (픽셀)	Brightness/Contrast 조절	0.3
Pixel	Gaussian Blur (3~5 kernel)	0.2

10.3 Ablation Study (성능 분석 15% 항목)

Ablation = 어떤 구성요소를 빼봤을 때 성능 차이 측정. 평가 기준 "성능 최적화" 항목 대응. Week 3에 다음 표를 만들 예정:

실험	Augmentation	예상 mIoU
Baseline	없음	0.70
+ Spatial	Flip + Rotation	0.76 (+6%)
+ Pixel	+ Brightness/Contrast/Blur	0.79 (+3%)

→ "Augmentation 적용 시 mIoU 9%p 향상" 한 줄로 정량적 어필 가능.

11. 핵심 개념 H — Grad-CAM (해석 가능성)

11.1 무엇인가

Gradient-weighted Class Activation Mapping. CNN이 "왜 이 부분을 그 클래스로 판단했는지" 픽셀 단위 heatmap으로 시각화. CVPR 2017 Selvaraju et al.

11.2 작동 원리 (개념적)

특정 클래스의 출력에 대한 gradient를 마지막 conv layer까지 역전파. 각 채널이 클래스에 얼마나 기여하는지 가중치로 변환 후 heatmap으로 표시.

11.3 우리 U-Net에서의 적용

U-Net은 분류기와 달리 픽셀 단위 출력이라 약간 다르게 적용:

- Hook 위치: encoder의 가장 깊은 layer (`model.encoder.layer4[-1]`)
- Target: `SemanticSegmentationTarget` 클래스 사용 (pytorch-grad-cam 제공)
- 결과: 특정 클래스(예: nose)에 대한 영역별 활성화 heatmap

11.4 발표 시 임팩트

최종 발표에서 5장의 Grad-CAM 시각화 (코/눈/입/턱/이마)를 보여주면:

"AI가 사진의 이 부분을 보고 코로 판단했어요" 라는 명확한 설명 가능. 교수님 평가 기준 "설명 가능한 비전 AI" 15% 항목 핵심 어필 포인트.

12. 핵심 개념 I — CelebAMask-HQ 데이터셋

항목	내용
출처	Lee et al., CVPR 2020
크기	30,000장 (1024×1024 또는 256×256 미리)
라벨	19개 부위 (skin, nose, eye, mouth, hair, ...) 픽셀 단위 mask
라이선스	비상업 연구 용도 (학술 발표 OK)
다운로드	Hugging Face datasets ('lmsanky/celebamask-hq-256', 1.42GB)
분할	Train 24K / Val 3K / Test 3K

12.1 왜 이 데이터셋인가

- 학술 표준: CVPR 2020 게재 → 평가 기준의 "질·양" 어필
- 픽셀 단위 정밀 라벨: 세그멘테이션 학습에 적합
- 충분한 양: 30K = 학습/검증/테스트 분할 충분
- 접근성: Hugging Face 미러로 한 줄 다운로드

12.2 우리가 푼 문제 — 턱·이마 라벨 부재

CelebAMask-HQ에는 jaw와 forehead 라벨이 직접 없음 (skin에 묶임). 해결: 학습은 5 클래스(bg/nose/eye/mouth/skin)만 진행하고, 추론 후 MediaPipe 랜드마크로 skin 영역을 jaw/forehead로 분리. 학습 데이터의 진정성을 유지하면서 우리 task에 맞춤.

13. 핵심 개념 J — Transfer Learning

13.1 개념

이미 다른 task에서 사전학습된 모델의 가중치를 가져와 새 task에 적용. 처음부터 학습할 때보다 학습 데이터 적어도 잘 동작, 학습 시간 ↓.

13.2 우리 U-Net의 적용

- Encoder = ResNet-34 + ImageNet 사전학습 가중치
→ ImageNet 100만 장으로 학습된 시각 특징(엣지/텍스처/형태)이 이미 들어있음
- Decoder = 무작위 초기화 (face parsing은 ImageNet에 없는 task)
- Fine-tuning: 전체 가중치를 우리 데이터로 추가 학습

13.3 발표 시 강조 (왜 이게 의미 있는가)

Transfer learning은 현대 딥러닝의 표준 관행이고 "처음부터 학습"보다 거의 항상 우월. 교수님 질문 가능: "왜 처음부터 학습하지 않았나?" → "30K 데이터로 ResNet을 처음부터 학습하면 underfit 가능. ImageNet 사전학습 가중치 활용이 일반적 best practice".

14. 예상 질문 + 모범 답변

Q1. 왜 SC-FEGAN을 직접 학습하지 않았나?

GAN 학습은 수주~수개월 소요되고 학습 안정성이 까다롭다 (mode collapse, vanishing gradient). 1달 일정에서는 불가능. 메인 학습 컴포넌트는 U-Net이고, SC-FEGAN은 시각화 도구로 활용. 이는 현대 딥러닝 프로젝트의 일반적 접근 — 작은 컴포넌트는 학습하고 큰 사전학습 모델은 그대로 활용.

Q2. 왜 U-Net인가? 더 최신 모델은 없나?

① U-Net은 의료/세그멘테이션의 표준 아키텍처 (Ronneberger 2015 CVPR). ② 우리 task는 픽셀 단위 부위 분할이라 segmentation network가 자연스러움. ③ "계층적 특징 추출 + skip connection"이 수업에서 배운 구조적 원리에 가장 직접적으로 대응. ④ 1달 안에 학습/튜닝 가능한 규모.

Q3. 왜 ResNet-34 인코더인가? ResNet-50이 더 좋지 않나?

ResNet-50은 더 깊지만 parameter 수가 2배이고 학습 시간 ↑. ResNet-34는 face parsing에서 검증된 trade-off (속도↔정확도 균형). Ablation으로 ResNet-50 시도는 Week 3 옵션 작업.

Q4. 30K 데이터셋이 너무 많지 않나?

Week 2 PoC에는 5K subset부터 시작 (1 epoch ~1분). Week 3 본 학습에서 24K 전체 사용 (10 epoch ~50분). 점진적 확장으로 위험 관리.

Q5. mIoU가 낮으면 어떻게 할 건가?

① Augmentation 강화 (Ablation 결과 보고 추가), ② Loss 가중치 조정 (Dice 비중 ↑), ③ Encoder를 더 깊게 (ResNet-50), ④ Class weight로 작은 클래스(nose) 보강. 한계가 명확하면 발표에서 "향후 과제"로 명시.

Q6. 성형 윤리적 문제는?

학술 데모임을 명시. 의료 자문이 아니라 시각화 도구. 발표 슬라이드에 "한계 및 윤리적 고려" 섹션 포함 예정 (편향, 의료 검증 부재, 동의 등). 실제 적용 시 의료법·개인정보보호법 등 추가 규제 필요.

Q7. CelebAMask-HQ는 서양인 위주. 한국인 얼굴에서 일반화 되나?

정확한 답: 편향 가능성 있음. 향후 한국인 얼굴 데이터(AI-Hub 등)로 추가 fine-tuning 필요. Week 4 한계점 슬라이드에 명시.

Q8. Grad-CAM이 Segmentation에서 의미 있나? 분류용 아닌가?

원래는 분류용이지만 SemanticSegmentationTarget 변형으로 segmentation에도 적용 가능. Encoder의 가장 깊은 layer를 hook → 특정 클래스(예: nose)의 예측 영역에 대한 활성화 heatmap. "AI가 이 부분을 보고 nose로 판단"이라는 해석을 제공.

Q9. 룰베이스 추천은 왜 ML로 안 했나?

① 시술 추천 라벨링된 데이터셋 없음 (의료 데이터는 비공개 + 라벨링 비용), ② 룰베이스가 설명 가능 ("황금비 벗어남 ↓ → 코끝 성형 추천"), ③ 본 프로젝트의 핵심은 segmentation이고 추천은 보조.

Q10. v1 vs v2 무엇이 결정적으로 달라졌나?

U-Net 자체 학습 추가 — 이게 핵심. 평가 기준 40% "모델 설계" 항목 대응. 더불어 학술 데이터셋(30%), CV 표준 지표(15%), Grad-CAM(15%) 모든 항목이 같이 개선.

15. 발표 시 강조 포인트

15.1 슬라이드 4 (U-Net) — 가장 중요 ★

발표 시간 8장 중 1분 이상 투자. 다음 3개 키워드를 명시적으로 입에 올릴 것:

- ① 계층적 특징 추출 (encoder)
- ② Skip Connection (encoder↔decoder)
- ③ 픽셀 단위 분류 (output)

→ 교수님 평가 기준 "CNN 구조적 원리" 문장을 그대로 인용한 표현.

15.2 슬라이드 5 (데이터셋) — 데이터 타당성 어필

"CelebAMask-HQ는 CVPR 2020 학술 표준 데이터셋" 한 마디만 강조. 30K 양 + 픽셀 단위 라벨 + 학술 출처 = 30% 항목 만점.

15.3 슬라이드 6 (평가) — CV 지표 명시

mIoU, Dice, Confusion Matrix, Ablation를 빠르게 나열. 교수님 원문 "Confusion Matrix, IoU, mAP"에서 우리가 IoU 계열을 사용. + Augmentation 비교표(예시) 보여주면 "성능 최적화 시도" 어필.

15.4 자신 있게 말할 한 줄

"U-Net의 계층적 특징 추출과 skip connection을 활용해 픽셀 단위 부위 분할을 자체 학습하고, 그 결과를 사전학습된 SC-FEGAN의 입력으로 사용해 객관적이고 정밀한 시술 후 시각화를 제공합니다."

15.5 절대 하지 말 것

"사전학습 모델을 그냥 가져다 썼어요" — 학습 컴포넌트 강조 누락

Grad-CAM, IoU 같은 용어 모르는 듯 얼버무리기

데이터셋 출처 못 답하기

왜 U-Net 인지 못 답하기 (수업 원리 연결 못 함)

현재 mIoU 값 없다고 자신감 잃기 (Week 2 PoC는 발표용 아님)

부록 — 참고 자료

- U-Net 원논문: Ronneberger et al., "U-Net: Convolutional Networks for Biomedical Image Segmentation" (MICCAI 2015)

- CelebAMask-HQ: Lee et al., "MaskGAN: Towards Diverse and Interactive Facial Image Manipulation" (CVPR 2020)
- SC-FEGAN: Jo & Park, "SC-FEGAN: Face Editing GAN With User's Sketch and Color" (ICCV 2019)
- Grad-CAM: Selvaraju et al., "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization" (CVPR 2017)
- MediaPipe Face Mesh: Google, ai.google.dev/edge/mediapipe/solutions/vision/face_landmarker
- segmentation_models_pytorch: github.com/qubvel-org/segmentation_models_pytorch
- pytorch-grad-cam: github.com/jacobgil/pytorch-grad-cam
- Combo Loss: Hashemi et al., "Combo Loss: Handling Input and Output Imbalance in Multi-Organ Segmentation" (CMIG 2019)

이 문서는 발표 직전 자료입니다. 항상 plan_kim_0518_01.md 및 research_unet.md를 참고하세요.

작성: kim · 2026-05-18